科研基础学习

前言

本次入门培训**为期一个半月（以内）**，希望能在培训任务的指引下带你快速掌握可信人工智能相关科研所需的基本技能。培训结束后需要**提交一份文献阅读报告和进行汇报答辩**。

注：内部学习文件，请勿外传！

目标

- **深度学习理论基础：**
  - 了解深度学习中 (尤其是计算机视觉的)各类重要任务及其对应的经典模型、数据集、训练过程等
  - 掌握ViT和LLM的基本概念和原理 [**非常建议通过知乎、相关的教程、surveys学习**]
  - 掌握LLM-based Agent的基本概念和原理 [**非常建议通过知乎、相关的教程、surveys学习**]
  - 掌握Text-to-Image Diffusion Model的基本概念和原理 [**非常建议通过知乎、相关的教程、surveys学习**]
- **深度学习代码基础：**
  - 掌握Python、Pytorch的基本使用方法
  - 掌握Anaconda的基本使用和基于此的环境管理
  - 能远程连接Linux服务器执行深度学习任务
  - 在给出GitHub仓库的情况下能（结合论文）跑通代码，能对现有的代码进行相关改进
- **科研基础：**
  - 了解Google Scholar、arXiv、Semantic Scholar的基本使用
  - 学会如何进行文献阅读和管理，学会如何做文献笔记和撰写调研报告
  - 掌握LaTeX的基本使用方法，学会如何使用LaTeX撰写文档
  - 基本的PPT制作：PowerPoint或LaTeX中的Beamer包
  - 如何高效的撰写（双）周报
  - 如何进行高效的汇报和会议
  - 如何进行高效的时间和任务管理

- 协同工具（如飞书）的基本使用

具体学习内容

深度学习的理论基础 (10天内)

这块不用看，有点扯

1. 李宏毅机器学习课程: 2/18，2/25，3/04，3/25，4/22，4/29这几天的课程。建议完成布置的作业并听助教的HW讲解，**在5天之内完成这个课程**。
2. 吴恩达深度学习课程: 和上面的课程有一些重复，可以用来速刷查漏补缺，建议**在2天之内完成这个课程**。
3. 深度学习面试宝典: 数学、机器学习、深度学习、计算机视觉、传统图像处理，**建议2天内完成理解和记忆**。
4. 斯坦福视觉课CS231n：速刷，查漏补缺，建议**在3天之内完成这个课程**。
5. 李宏毅LLM & Diffusion Model课程：推荐快速过完Youtube上LLM和Diffusion相关的课程，不懂的建议结合代码和知乎解读等学习。

深度学习的代码基础 (7天内)

1. **Python基础**：Python基础教程、numpy基础
2. **Jupyter Notebook:** Jupyter Notebook英文教程、中文教程 (**需要学会如何在远程服务器上搭建Notebook**)
3. **Pytorch**: 官方教程 (可以自行寻找中文版学习)、小土堆教程
4. **Anaconda**: 知乎教程（**重点掌握如何下载、安装、创建环境、激活环境、安装需要的库、删除环境**）
5. **Linux**：bilibili教程 (**重点掌握基本的命令和如何使用screen等任务后台管理、FileZilla等文件传输工具**)
6. **Git**：bilibili教程（**重点掌握如何进行版本控制**）

可信人工智能基础 (10天内)

1. **针对传统模型安全的基本概念**: Data Security for Machine Learning: Data Poisoning, Backdoor Attacks, and Defenses、Adversarial Machine Learning: A Systematic Survey of Backdoor Attack, Weight Attack and Adversarial Example

2. **文生图扩散模型的攻击与防御:** Attacks and Defenses for Generative Diffusion Models: A Comprehensive Survey,
3. **了解大语言模型的攻防与红队:** A survey on large language model (LLM) security and privacy: The Good, The Bad, and The Ugly, Operationalizing a Threat Model for Red-Teaming Large Language Models (LLMs)
4. **了解基于大模型的智能体攻击与防御**：The Emerged Security and Privacy of LLM Agent: A Survey with Case Studies，AgentBench: Evaluating LLMs as Agents， Watch Out for Your Agents! Investigating Backdoor Threats to LLM-Based Agents
5. **面向模型的版权保护**：英文survey、中文survey、MOVE: Effective and Harmless Ownership Verification via Embedded External Features
6. **面向数据集的版权保护：**Black-box Dataset Ownership Verification via Backdoor Watermarking、Untargeted Backdoor Watermark: Towards Harmless and Stealthy Dataset Copyright Protection、Radioactive Data: Tracing through Training

注：在培训阶段我们不提供实验室的计算资源，你可以从Google或者别的地方很容易的薅到一开始学习所需要的少量GPU资源（具体途径可以自行搜索）。等到正式进入到RA的科研阶段，实验室会提供所需的计算资源 :)

科研基础 (1天内)

1. 了解Google Scholar (如何进行高级搜索、订阅)、arXiv (如何进行搜索、订阅、Connected Papers)、Semantic Scholar的基本使用
2. 不会的东西优先学会使用GPT、Google、Wiki、知乎、CSDN等资源查找相关的信息，实在不行再去问别人
3. **文献的阅读和记笔记方式**：从abstract读到intro，再读到方法和实验。读的时候按照顺序思考并回答如下问题：
   a. 作者旨在做什么事（1句话）
   b. 这件事的难点在哪里（1-2句话）
   c. 宏观角度来说，作者是怎么解决的（1-2句话）
   d. 作者的方法技术细节
   e. **所提的方法为什么有效**
   f. 作者做了哪些重要实验来支持他的观点
   g. 作者的主要贡献是什么
   h. 这个工作还有什么（潜在的）缺陷和可以改进的地方

4. **文献的记录和管理方式：** 文献记录和管理模板 、 学习到的搭配和表达
5. **Latex:** bilibili教程、tablesgenerator、注册并了解overleaf的基本使用
6. **基本的PPT制作**: Beamer知乎介绍、Beamer Overleaf模板、 PPT模板及示例.pptx
   a. **中文一律宋体，英文一律Times New Roman字体**
   b. **确保易读性**：字体不能过小、每页字不能太多、图表下方要配有简单的结果解释、整体需要图文并茂
   c. 一般不允许使用具有图片堆叠的动画，保证导出PDF时PPT依旧正常
   d. 图片、表格需要有标题。涉及到参考文献的需要设置引用；参考文献放在本页PPT的最下方；
7. **如何高效的撰写（双）周报：** **周报模板**
   a. 所有周报在一个文档内，把**最新一期的内容放在文档最上方**（整体而言，周报文档是按照时间顺序倒序的）
   b. 请把周报命名为'周报-name' (e.g., ‘周报-李一鸣’)
   c. 请注意内容的可读性（排版、语言等）
   d. 需要包括足够的细节，例如重要实验的结果等
   e. **如果有针对具体研究课题的讨论，请在讨论结束后半天内把讨论的内容总结到周报中，并把链接发我核对。具体需要总结的内容有：本次讨论的细节以及讨论后定下来的未来工作安排**
   f. **每周六晚上10点提交，时间跨度为上周六到本周六 (建议提前定好闹钟，不然很容易忘)**
   g. **请把周报的权限改为‘互联网上获得链接的人可阅读’，并通过微信将周报的链接私发给我**
   h. 请保持周报包含**足够多信息的同时做到尽量简洁**，周报同时是我对大家课题的一个备忘录。基于这个考量，一些**与科研课题无关的信息请不要详细展开**，例如，论文的阅读笔记啥的可以放在别的doc里，只需要说你读了论文，笔记丢个链接在这就行（当然，放不放笔记链接完全是你的自由）。
8. **如何进行高效的汇报和会议**
   a. 汇报、会议、论文的本质都是向其他人快速传递信息，因此**整体而言是一个总分结构** (具体的参考模板见下)
   b. **汇报论文的时候：** 今天讲哪几篇-->为什么要讲这几篇-->[论文研究的问题-->论文的motivations (及难点)-->概括的说这篇论文是怎么解决这个问题的-->论文的核心贡献-->方法的具体细节-->方法为什么有效-->能支撑论文观点的实验+你觉得有必要讲、学习的相关实验]-->这篇工作有什么潜在缺陷-->从中学习到了什么，下一步有什么打算（e.g., 改进它）
   c. **汇报实验的时候：** 做了什么实验-->为什么要做这些实验（+我们期待看到什么样的结果）-->实验有哪些结果-->这些结果说明了什么-->目前遇到了什么障碍/困难/需要讨论的独特现象-->下一步的计划
   d. **高效会议**

    i. 会前至少一天按照上述要求做好PPT，并将其发到群里
    ii. 会议前提前准备，自己先过一遍PPT，不要到时候讲的磕磕绊绊
    iii. 与会议当前主题无关的事情放到整体会议结束后再讲
    iv. 每个人的论文和实验汇报都尽量控制在30分钟以内，做到富有信息量且简洁
9. **如何进行文献调研 (TO-DO Yiming1016)**

10. **如何进行高效的时间和任务管理**
    a. 提前维护一个长期的（建议一个学期）to-do list，把重要的任务及其时间节点都列在上面
    b. 针对每个重要任务基于子任务进行拆分，根据DDL来定一个每个子任务的时间，形成一个整体的schedule。**记得打好提前量**，不要时间正好卡DDL，不然万一中途有什么事这个任务就逾期了。
    c. 建议维护一个短期的（一个月）的时间表，按照每小时/每半小时进行拆分，规划好一周内每天的时间。**记得给自己留出足够的休息时间**。
    d. 学会使用备忘录，推荐'高效Todo'APP。
    e. 可以使用一些辅助工具来监督学习，例如Qbserve、番茄钟等
11. 飞书的基本使用：重点学习云文档、任务、会议、飞书汇报
12. **什么是好的研究?**
    a. 定义、解决了一个新（**且重要**）的问题
    b. 推动、改变了一个潮流或认识（i.e., inspiring、unexpected、fancy的研究）
    c. 简单而不平凡 (大道至简): simple yet effective methods **with deep insights or even theoretical supports**.

需要完成的小测试：文献阅读报告及汇报（10天内）

阅读报告

1. **Section 1. 基本概念**: 对大语言模型和文生图扩散模型所面临的威胁进行分析，具体来说，你应该详细列出目前存在哪些攻击（或威胁），讨论攻击如何产生，有何种现实威胁，并简单讲解目前防御的思路；阐述他们之间的联系与区别。内容应当简明扼要，主要谈理解，拒绝从网上直接复制粘贴，不要超过20页。建议在完成Section 2后应该回来重新查漏补缺和进一步修正。

2. **Section 2. 对论文的理解**：从上面的攻击（或威胁）中选择5篇论文（至少从3种不同威胁中选择），精读论文并写出阅读报告，你的报告应该包含对创新点的分析、对方法以及实验的详细解读，以及对缺点的分析。内容应当简明扼要，主要谈理解，拒绝从网上直接复制粘贴，不要超过10页。
3. **Section 3. 论文前沿调研：**选择上述威胁中的任意一个具体的前沿方向，并对这一整个主题的论文进行全面调研。你应该想办法包括尽可能多和尽可能新的文献（截止到24年9月），并在这个部分仔细分析该方向目前发展到什么程度了，还遗留了哪些问题有待解决。
4. **Section 4. 未来展望**：你需要在本文的全部内容的基础上，展现你在考核期间学习到的内容、对可信人工智能领域的若干思考和未来展望，阐述自己在考核期间的心得和收获，并对考核任务的难度、平滑度进行点评和提出建议，同时阐明自己在接下来这段时间的学习目标和感兴趣的研究方向。

注：

- 请使用Overleaf模板**按照上述要求**撰写
- 请确保在文档中进行了合理的引用（会议论文引用只保留作者、标题、会议缩写、年份信息，具体见模板）
- 禁止直接翻译原文、直接复制粘贴已有网上的资料（参考的话需要合理引用）
- 早期的一些工作（尤其是发在安全领域的）有些写的确实相对晦涩难懂，不用过于担心，可以结合一些网上的博客、相关教程等进行学习

结束语

通过本次培训，你应该已经具备了进行可信人工智能领域前沿研究的所有基础。更为重要的是，你应该已经抵达了生成式模型攻防领域目前人类的认知边界和学术最前沿。接下来，让我们一起拓宽这些领域的知识边界，共同做出一些有影响力的、世界一流的研究! 感谢你的努力和坚持，你做的很好 :)